Towards artificial general 술래잡기와숨바꼭질용2D맵을만드는 intelligence

15기 배연욱 김시원 현승원
16기 김현준 전유하

2026-2 DSL 모델링 강화학습

배경

게임 소개

술래
좁고 긴 시야. 도망자를 잡거나 제한 시간 120초를 버티면 승리

도망자
넓은 시야. 발전기를 켜서 탈출구를 열고, 빠져나가야 승리

맵은 문으로 이어진 방 구조
Lv1→Lv2→Lv3(최종)는 맵 하나에서 단계별로 기능을 켬

관측	시야 안 정보 46차원 (시야 밖 정보: 마지막 목격 위치, 경과 시간)
행동	9가지: 정지 + 8방향
보상	승패 ±10 + 미션 진행 + 접근 shaping

중간발표 요약

스터디 A-D

A	커리큘럼	단계별 학습이 직접학습을 앞섬. 각 발전기 개수 1.28, 0.23
B	크로스플레이	PPO 학습 시 한쪽을 고정하면 다른 쪽이 강해짐
C	안개 ablation	안개(fog)의 구성 요소 중 시야 반경보다 벽 가림이 주된 역할
D	사전등록	보상과 규칙을 수정하여 학습하니 단계별 학습과 직접 학습이 비슷

전환

플레이어 학습 → 맵 생성 학습

Study A-D의 도망자 승률은 거의 항상 0%
→ Why? 맵의 배치와 규칙 때문일 수도 있음

강화학습 에이전트에서 휴리스틱 에이전트로 변경

주 지표(맵별 |도망자 승률 − 0.5| = |err|)를
이용하여 맵 구조의 영향력 확인

맵	|err|
Lv3	0.167
Lv2	0.417
Lv1, Arena, Corridors	0.500
Pillars, Mansion	0.500

켜야 하는 발전기의 개수를 변경하자 대부분의 맵에서 도망자 승률 > 0%
→ 스터디 A-D의 승률의 일부는 맵의 배치와 규칙 때문일 것

Study E – Map study

1. 설계

anchor	원래 등록된 맵 13개를 그대로 채점
random	아무렇게나 무작위로 맵을 생성
mutate	방향성 없이 무작위로 편집만 반복
hillclimb	편집 후 더 좋아질 때만 채택
anneal	hillclimb에서 악화되는 편집 일부 채택
ppo	**편집 MDP 위에서 PPO 학습**

H1 ppo < random, mutate
H2 ppo < hillclimb, anneal
H3 기하적 특징 중 하나 이상은 |err|와 유의미한 상관관계

편집 MDP

행동
(커서 4방향 이동, 벽 생성/제거,
발전기/탈출구/스폰위치 변경, 무편집)
에피소드당 40번 편집, 302차원 관측 정보

보상
휴리스틱 vs. 휴리스틱 시뮬레이션 승률로 계산한 |err|

Study E – Map study

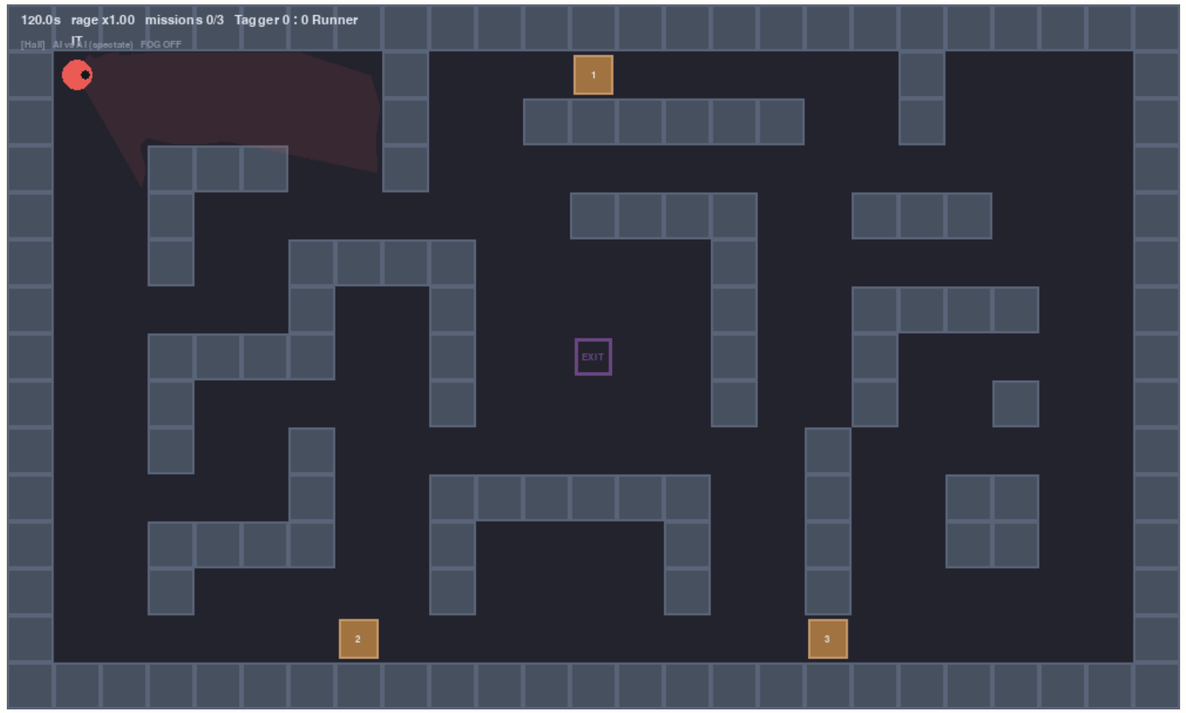
2. 결과

Best map |err|

0.021

H3 지표

8/14



H3 기하적 특징 중 하나 이상은 |err|와 유의미한 상관관계
지형 특징 14개 중 8개가 |err|와 유의미하게 연관
시야가 길면 술래가 자주 이김
발전기가 흩어지면 균형에 가까워짐

H1 ppo < random, mutate
PPO가 random, mutate보다 숫자상으로는 낮지만
통계적으로는 무의미

3. 음성 결과

H2 실패. anneal 0.079 < ppo 0.119
PPO가 anneal보다 숫자상으로도 나쁨
Training budget을 늘려도 동일. 오히려 편집 횟수 감소

Credit assignment problem
맵 편집을 스칼라 하나(|err|)로 평가함

방법	|err|
anneal	**0.079**
ppo	0.119
hillclimb	0.204
mutate	0.215
random	0.233

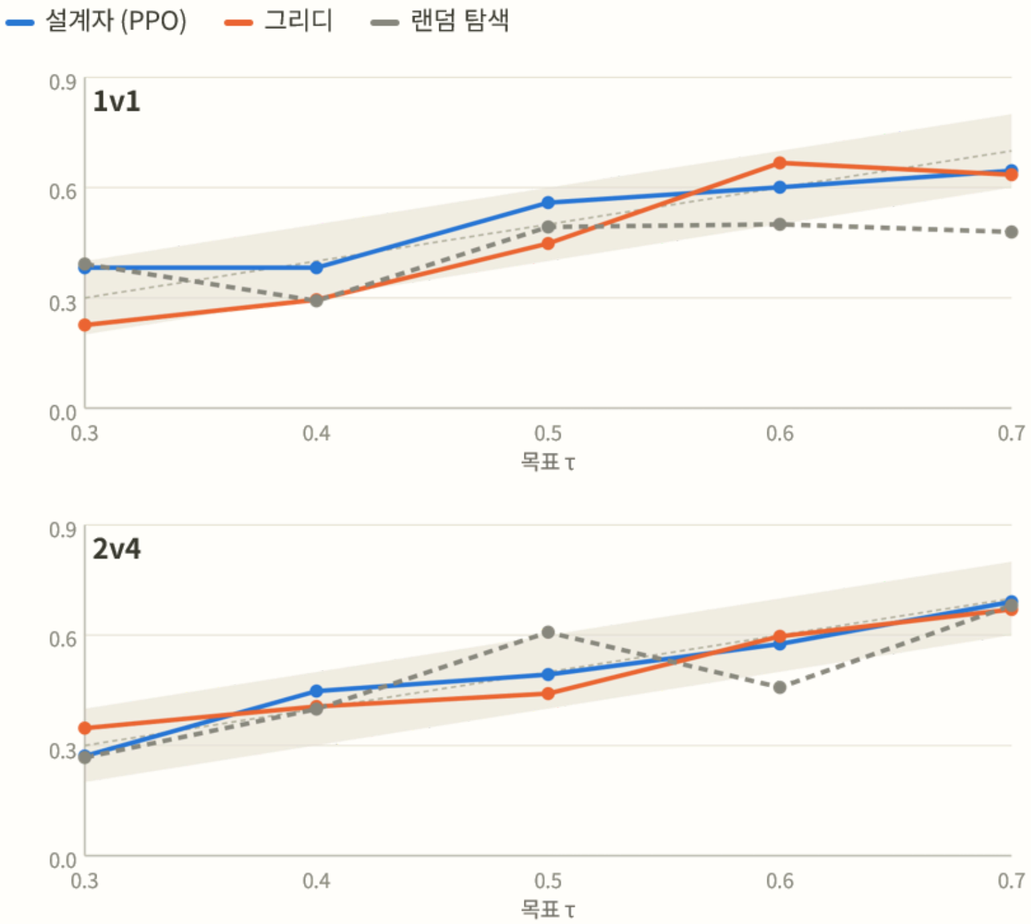
4. 스킬 및 캐릭터

스킬에 따라 승률이 달라짐
장거리 이동 스킬이나 하드 CC기가 승률에 큰 영향
장애물을 세우거나, 단거리 이동은 효과 작음

스킬 보유	|err|
술래	0.372
도망자	0.135

Study F – PPO 설계자

1. 보류 시드 검증



1v1 오차 |w−τ|

0.099

2v4 오차 |w−τ|

0.097

방법	|w−τ| 1v1	2v4	규칙 위반
설계자 (PPO)	**0.099**	0.097	7%
그리디	0.093	**0.069**	30%
랜덤 탐색	0.157	0.096	30%

1v1: PPO가 랜덤보다 유의하게 좋음(**p = 0.017**), 그리디와는 차이 X

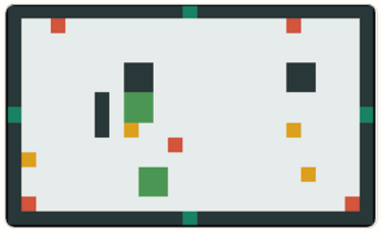
2v4: **그리디**가 최선

PPO의 강점: 규칙 준수, 낮은 추론 비용

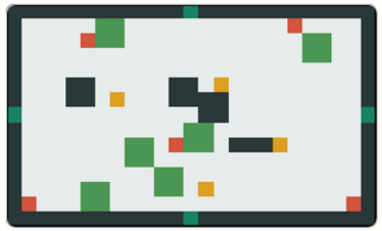
Study F – PPO 설계자

2. 구조 시각화

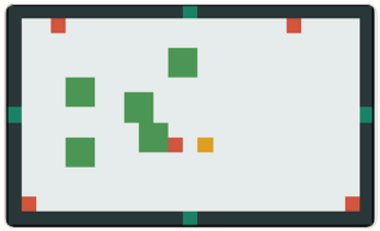
1v1



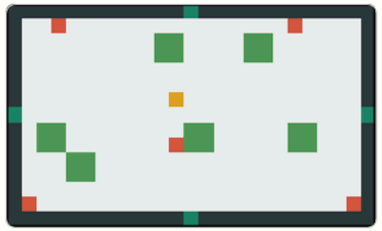
τ=0.3 → 0.38



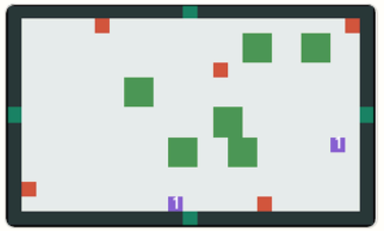
τ=0.4 → 0.42



τ=0.5 → 0.54

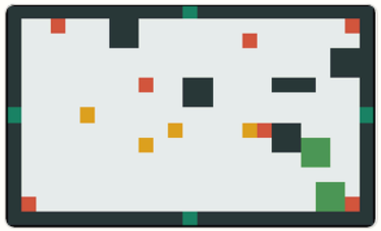


τ=0.6 → 0.60

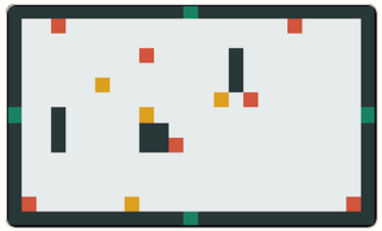


τ=0.7 → 0.71

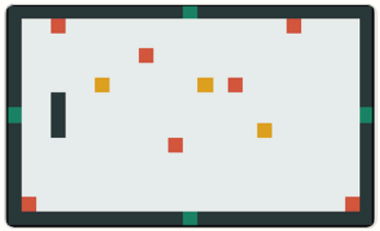
2v4



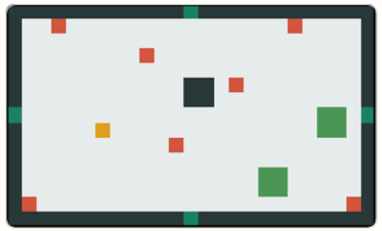
τ=0.3 → 0.29



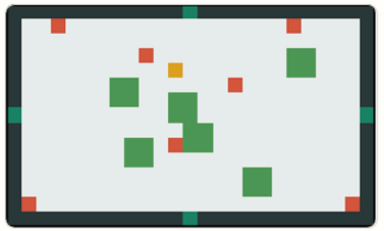
τ=0.4 → 0.38



τ=0.5 → 0.50



τ=0.6 → 0.58



τ=0.7 → 0.71

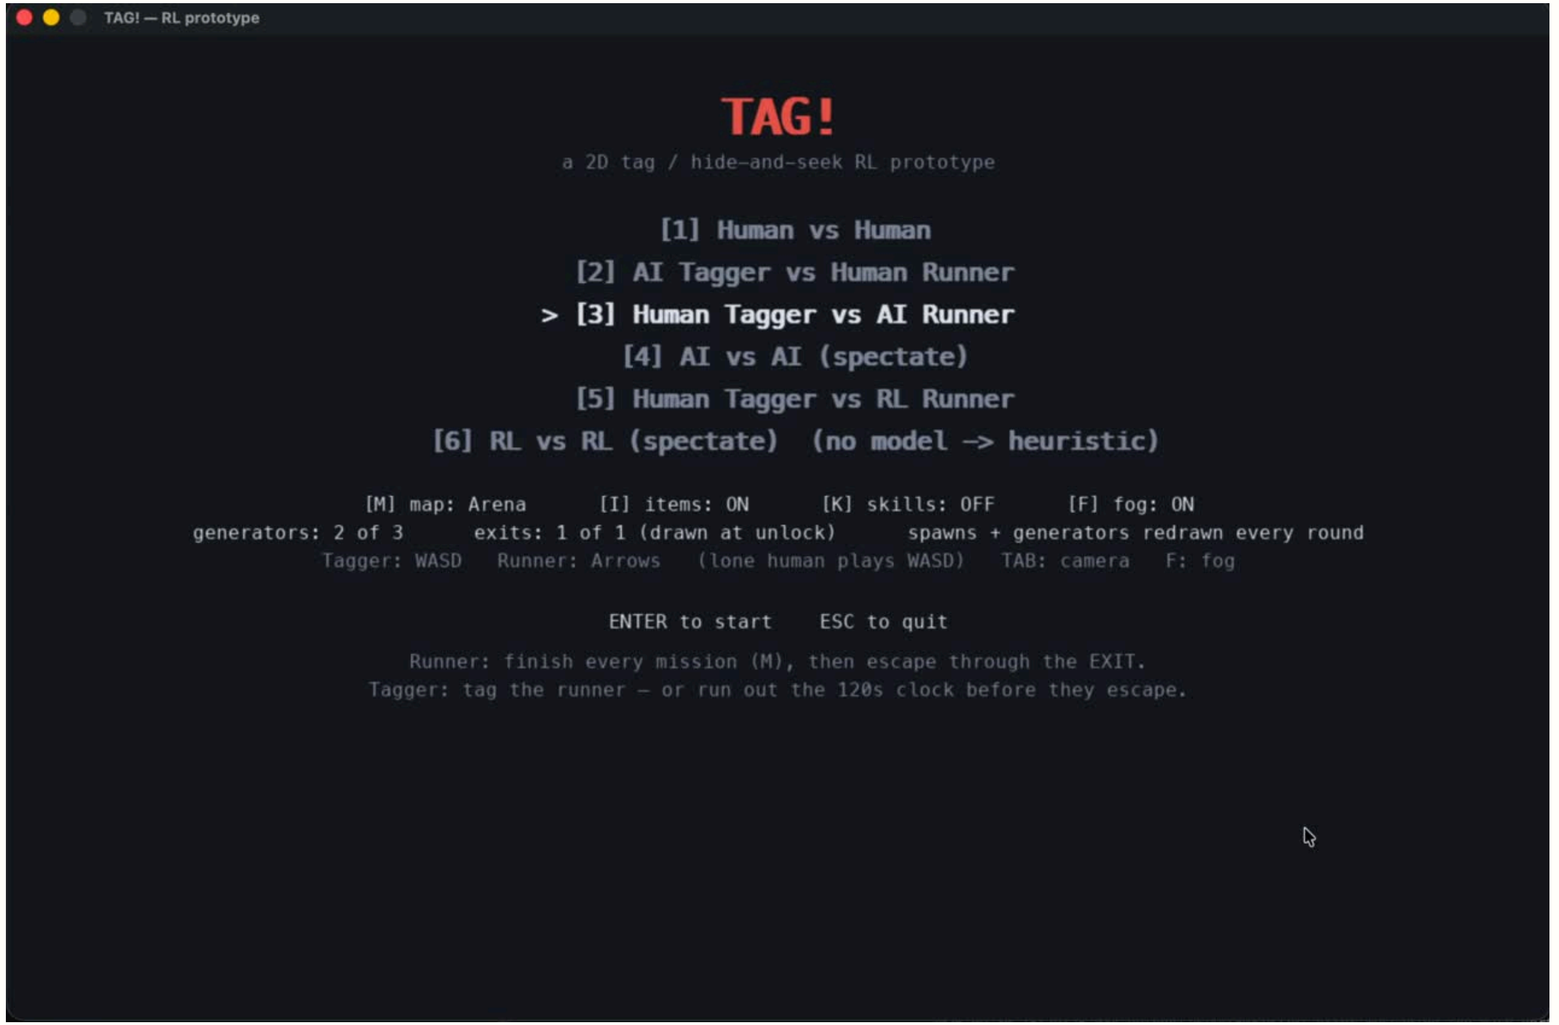
구조	유리한 쪽
내부 벽	술래
아이템 패드	술래
덤불	도망자
순환로	도망자

τ가 높을수록 **벽·아이템 ↓, 덤불 ↑**

랜덤 맵에서는 **반대**로 1v1은 은신, 2v4는 개방·순환

도망자 2명 추가마다 승률 약 **+0.25**

Demo


TAG! — RL prototype
TAG!
a 2D tag / hide-and-seek RL prototype
[1] Human vs Human
[2] AI Tagger vs Human Runner
> [3] Human Tagger vs AI Runner
[4] AI vs AI (spectate)
[5] Human Tagger vs RL Runner
[6] RL vs RL (spectate) (no model -> heuristic)
[M] map: Arena [I] items: ON [K] skills: OFF [F] fog: ON
generators: 2 of 3 exits: 1 of 1 (drawn at unlock) spawns + generators redrawn every round
Tagger: WASD Runner: Arrows (lone human plays WASD) TAB: camera F: fog
ENTER to start ESC to quit
Runner: finish every mission (M), then escape through the EXIT.
Tagger: tag the runner — or run out the 120s clock before they escape.

Result

플레이어 환경에서 게임 환경 설계로

→ 게임의 균형은 플레이어뿐만 아니라 게임 환경으로부터도 영향을 받음. 맵, 규칙, 스킬도 설계 필요

1) 맵 구조를 통해 균형 조절 가능

- 기하 지표 14개 중 8개가 승률·균형 오차와 유의하게 연관
- 탐색으로 균형에 가까운 맵 발견: |err| = 0.021

2) PPO의 효과는 task마다 다름

- Study E: anneal 0.079, PPO 0.119
- Study F: 정확도는 그리디와 비슷, 강점은 규칙 준수와 낮은 추론 비용

Thank you